

Desafío Data Engineering

Hola! ¿Cómo andas? Desde el equipo de Longevo queremos darte la bienvenida a este desafío, esperando que puedas resolverlo de la mejor manera y así poder avanzar en el proceso de selección.

Antes que nada, queremos agradecer el tiempo invertido en poder realizar los ejercicios propuestos, y por supuesto, cualquier feedback al respecto de los mismos es más que bienvenido.

Por cualquier duda al respecto, no dudes en contactarte con nosotros a los siguientes mails: martin.jourdan@longevo.com

A continuación, te vamos a proponer un contexto que va a requerir análisis y toma de decisiones.

Contexto

La empresa recibe un archivo CSV diario en S3 con ventas:

```
SQL
order_id
user_id
amount
currency
status
created_at
updated_at
```

Características:

- El archivo puede llegar con retraso.
- Puede enviarse más de una vez.
- Puede incluir correcciones de hasta 7 días hacia atrás.

- En 6 meses el volumen crecerá 5–10x.
- Finanzas necesita métricas diarias confiables.

Stack disponible:

- Airflow
- Python
- Redshift

Parte 1 – Diseño del Pipeline (Principal)

Describir cómo implementarías el pipeline end-to-end.

Incluir:

1. Flujo general (extract → transform → load).
2. Cómo lo orquestarías en Airflow.
3. Estrategia de carga en Redshift:
 - ¿Full load o incremental? ¿Por qué?
 - ¿Usarías tabla staging?
4. Cómo aseguramos:
 - Idempotencia
 - Manejo de duplicados
 - Re-procesamientos seguros
5. Cómo manejar correcciones de hasta 7 días.
6. Qué validaciones de datos implementarías y cómo detectarías fallas automáticamente.

Justificar las decisiones. No buscamos infraestructura detallada sino criterio técnico.

Parte 2 – Escenarios

Responder brevemente qué harías en cada caso:

1. El archivo no llega un día.
2. Llega dos veces con contenido diferente.

3. Se agrega una nueva columna al CSV.
4. El volumen crece 10x.
5. El dashboard muestra números distintos a los del sistema transaccional.

Acá evaluamos razonamiento operativo y capacidad de diagnóstico.

Parte 3 – Modelado y SQL

1. Diseñar la tabla final en Redshift (columnas principales + claves).
2. Explicar qué elegirías como:
 - Sort key
 - Dist key
 - Por qué.
3. Escribir una query que:
 - Calcule ventas diarias por moneda.
 - Detecte posibles duplicados por `order_id`.

No buscamos sintaxis perfecta sino decisiones coherentes.

Parte 4 – Reflexión

Responder:

- ¿Qué trade-offs asumiste?
- ¿Qué parte del diseño te genera más dudas?
- Si este pipeline fuera crítico para el cierre contable, ¿qué reforzarías?

Qué esperamos ver

Buscamos claridad de pensamiento, decisiones justificadas y capacidad de anticipar problemas.

No buscamos una solución perfecta ni extremadamente compleja.

Entrega

Para la entrega de los mismos, te pedimos adjuntar en el mail o idealmente, en un repositorio Gitlab o Github privado (darnos permisos para poder acceder)